

HD-EPIC: A Highly-Detailed Egocentric Video Dataset

HD-EPIC: A Highly-Detailed Egocentric Video Dataset

Panoramica Generale

HD-EPIC (Highly-Detailed EPIC) è un dataset validazione di video egocentrici basati in cucina, annotati manualmente con etichette ground-truth altamente dettagliate e interconnesse. Il dataset rappresenta il primo tentativo di raccogliere registrazioni non scriptate in ambienti domestici reali con annotazioni dettagliate paragonabili a quelle degli ambienti di laboratorio controllati.

Caratteristiche principali:

- **41 ore** di video in 9 cucine diverse
- **156 video** con durata media di 15.9 minuti ciascuno
- **413 fixture** di cucina con digital twin
- **69 ricette** complete
- **59,454 azioni** fine-grained annotate
- **50,968 eventi** audio annotati
- **20,000 movimenti** di oggetti tracciati
- **37,000 mask** di oggetti sollevati in 3D
- **263 annotazioni** al minuto in media

Dettagli Annotazioni

Narrations (Descrizioni Azioni)

Le narrazioni sono state raccolte chiedendo ai partecipanti di descrivere:

- **Cosa** stanno facendo (what)
- **Come** lo stanno facendo (how)
- **Perché** lo stanno facendo (why)

Statistiche narrations:

- 59,454 segmenti di azioni annotati
- Durata media: 2.0 secondi ($\pm 3.4s$)
- 3.8× più parole/minuto rispetto a Ego4D
- 16,004 estrazioni di clausole "how"
- 11,540 estrazioni di clausole "why"

Recipe Steps (Passaggi Ricette)

Le ricette sono annotate con:

- ****Step temporali****: ogni passaggio della ricetta è temporalmente annotato
- ****Prep pairs****: ogni step è associato alle azioni preparatorie necessarie
- ****93.1%**** degli step hanno paired prep annotations
- Durata media prep: 54.5 secondi
- Durata media step: 78.2 secondi

Dettagli ricette:

- 69 ricette totali
- 6.6 step in media per ricetta
- 8.1 ingredienti in media per ricetta
- Durata media: 4 ore 48 minuti
- Durata massima: 2 giorni e 6 ore

Fine-Grained Actions

Le azioni sono annotate con:

- Verbi, nomi e mani estratte dalle narrazioni open-vocabulary
- Clusterizzazione gerarchica per compiti closed-vocabulary
- Boundary precisi (start/end time) per ogni azione

Categorie principali:

- Verb clusters (azioni)
- Noun clusters (oggetti)

- Distribuzione long-tailed tipica dei dataset egocentrici

Sound Annotations (Annotazioni Audio)

Eventi audio annotati con:

- Start-end times precisi
- Classi nominali (es: 'click', 'rustle', 'metal-plastic collision', 'running water')
- **50,968 annotazioni audio** da **44 classi** diverse

Digital Twin

Ogni cucina dispone di:

- **Digital twin completo** con fixture etichettate
- **413 kitchen fixtures** mappati in 3D
- Associazioni tra azioni e fixture (es: aprire/chiudere)
- Tracciamento presa/deposizione oggetti
- Point cloud multi-day per cucina
- Traiettorie camera 6DoF a 1kHz

Eye-Gaze (Direzione Sguardo)

- **60 FPS eye tracking**
- Rilevamento quando gli oggetti sono "primed" (guardati) prima di essere presi/deposti
- Associazione gaze con movimenti oggetti
- Abilita anticipation evidence-based

Statistiche Complete

Tabella Riassuntiva Dataset

Componente	Quantità	Dettaglio
------------	----------	-----------

Ore video totali	41.3 ore	4.46M frame
Numero video	156	Durata media 15.9 min
Partecipanti	9	3-7 giorni ciascuno
Cucina	9	Digital twin separate
Ricette	69	6.6 step/media
Ingredienti	558	558 unici
Azioni fine-grained	59,454	2.0s durata media
Eventi audio	50,968	44 classi
Movimenti oggetti	~20,000	Bounding box + mask
Object masks 3D	~37,000	Lifted to 3D
Kitchen fixtures	413	Per digital twin
Annotazioni/minuto	263	Densità media

Distribuzione Ingredienti

Categorie principali:

- Proteine: tonno, fagioli kidney
- Carboidrati: datteri, farina
- Grassi: panna acida, pinoli

Range calorici:

- Minimo: 274 calorie (Crispy Cucumber Salad)
- Massimo: 4.8K calorie (Lazy Cake)

Strumenti di Raccolta Dati

Dispositivo: Project Aria Glasses

- 3 camere forward (1 RGB + 2 SLAM)
- 7 microfoni
- Camere inward per eye gaze
- Risoluzione video: 1408×1408 a 30 FPS
- Eye tracking: 60 FPS
- SLAM: 30 FPS

Struttura del Dataset

Componenti Principali

1. ****Video Raw****

- Formato MP4
- 30 FPS, 1408×1408 risoluzione
- Totale 41.3 ore

2. ****Annotation Files****

- Recipe steps e prep pairs
- Fine-grained action boundaries
- Sound event timestamps
- Object movement tracks
- Gaze data

3. ****Digital Twin Data****

- Point cloud multi-day
- 3D bounding boxes per fixture
- Traiettorie camera 6DoF
- Object masks lifted to 3D

4. ****Metadata****

- Informazioni ricette

- Dati nutrizionali
- Timeline preparazione

Dimensioni Componenti

- **Video totale:** ~2.3 TiB (compreso download completo)
- **Annotations:** Diversi GB (JSON/CSV)
- **Digital twin:** Point cloud per ogni cucina
- **Total dataset:** Download completo disponibile in formato ZIP

Benchmark VQA

Panoramica Benchmark

Il benchmark VQA di HD-EPIC comprende **26,000 domande** progettate per valutare la comprensione video su 7 categorie principali:

1. **Recipes** (Ricette)
2. **Ingredients** (Ingredienti)
3. **Nutrition** (Nutrizione)
4. **Fine-grained Actions** (Azioni dettagliate)
5. **3D Perception** (Percezione 3D)
6. **Object Motion** (Movimento oggetti)
7. **Gaze** (Direzione sguardo)

Tipologie di Domande

Domande Innovative

1. **Recipe Nutrition**
 - Come cambia la nutrizione della ricetta quando vengono aggiunti ingredienti
 - Tracking dinamico delle proprietà nutrizionali

2. ****Multi-video****

- Domande su ricette preparate attraverso multiple registrazioni
- VQA che attraversa video lunghi multipli

3. ****Object Itinerary****

- Movimenti multi-hop di oggetti su video lunghi
- Relazioni rispetto alle fixture della cucina

4. ****Fixture Interactions****

- Quante volte un armadio/cassetto è stato aperto/chiuso
- Counting di interazioni specifiche

5. ****Action How/Why****

- Come/perché un'azione è stata eseguita
- Basato su narrazioni partecipanti (manners/reasons)

6. ****Anticipation with Gaze****

- Previsione prossimo movimento oggetto basato su gaze priming
- Anticipation evidence-based

Performance Baseline

Gemini Pro (long-context): 37.6% accuracy

- Dimostra la difficoltà del benchmark
- Evidenzia carenze attuali nei VLM (Vision-Language Models)

Altri Benchmark Inclusi

Oltre al VQA custom, HD-EPIC include 3 benchmark standard video:

1. ****Action Recognition****

- Riconoscimento azioni fine-grained
- Closed-vocabulary classification

2. ****Sound Recognition****

- Classificazione eventi audio
- 44 classi sonore

3. ****Long-term Video Object Segmentation****

- Tracking oggetti su video lunghi
- Segmentazione temporale

Download e Licenza

Link Download

Sito ufficiale: <https://hd-epic.github.io/>

Dataset completo: <https://data.bris.ac.uk/data/dataset/3cqb5b81wk2dc2379fx1mrhx47>

Formato: ZIP completo (~2.3 TiB)

DOI: 10.5523/bris.3cqb5b81wk2dc2379fx1mrhx47

Licenza

Licenza: Creative Commons Attribution 4.0 (CC BY 4.0)

Warranty: Disclaimer of Warranties and Limitation of Liability

Accesso

Il dataset è disponibile per:

- Ricerca accademica
- Sviluppo modelli AI/ML
- Validazione sistemi video understanding

BibTeX

```
@inproceedings{perrett2025hd-epic, title={HD-EPIC: A Highly-Detailed Egocentric Video Dataset}, author={Perrett, Toby and Darkhalil, Ahmad and Sinha, Saptarshi and Emara, Omar and Pollard, Sam and Parida, Kranti Kumar and Liu, Kaiting and Gatti, Prajwal and Bansal, Siddhant and Flanagan, Kevin and Chalk, Jacob and Zhu, Zhifan and Guerrier, Rhodri and Abdelazim, Fahd and Zhu, Bin and Moltisanti, Davide and Wray, Michael and Doughty, Hazel and Damen, Dima}, booktitle={IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)}, year={2025} }
```

Autori

Affiliazioni:

- University of Bristol (♣)
- Leiden University (♠)
- Singapore Management University (■)
- University of Bath (■)

Autori principali (Equal Contribution):

Toby Perrett, Ahmad Darkhalil, Saptarshi Sinha, Omar Emara, Sam Pollard, Kranti Kumar Parida

Altri autori:

Kaiting Liu, Prajwal Gatti, Siddhant Bansal, Kevin Flanagan, Jacob Chalk, Zhifan Zhu, Rhodri Guerrier, Fahd Abdelazim, Bin Zhu, Davide Moltisanti, Michael Wray, Hazel Doughty, Dima Damen

Documento generato per Ricca IT - Data: 2026