Progetto Deep Learning

Lorenzo Didomenico

Ottobre 2026

Contents

1 Introduzione **3**

2 Dataset e benchmark **3**
2.1 La categoria Nutrition 3

3 Preprocessing dei dati **4**
3.1 Download 4
3.2 Sottocampionamento 4
3.3 Estrazione dei frame per `image_nutrition_estimation` 4
3.4 Generazione dei pannelli 4

4 Valutazione e Metriche **5**
4.1 Prompt 5
4.2 Interpretazione delle risposte 5
4.3 Metriche 6
4.4 Esecuzione 6

5 Esperimento 1: Valutazione di VideoLLaMA 2 e LLaVA-Video **6**
5.1 Setup 6
5.2 Risultati 7
5.3 Dettaglio per prototipo 7

6 Esperimento 2: Valutazione dei VLM con la tecnica dei Video Panels **8**
6.1 Il metodo e la condizione del confronto 8
6.2 Risultati 8
6.3 Osservazioni sul Visual Prompting 9

7 Discussione e conclusioni **9**
7.1 Limiti 9
7.2 Sviluppi possibili 9
7.3 Conclusioni 9

1 Introduzione

I Video Large Language Model hanno raggiunto buoni risultati su video brevi e con un contenuto visivo esplicito, ma restano deboli quando la risposta richiede di seguire un'attività lunga e ripresa in prima persona. HD-EPIC [1] è un dataset egocentrico di attività di cucina annotato in modo molto dettagliato, a cui è associato un benchmark VQA a scelta multipla costruito proprio per testare questi modelli: nel paper originale i modelli testati restano molto lontani dall'accuratezza degli annotatori umani.

Questo progetto si concentra su una sola categoria del benchmark, *Nutrition*, composta da 200 domande a cinque opzioni divise in tre prototipi. È la categoria in cui la risposta dipende dall'individuare gli ingredienti lungo la preparazione ed in particolare dare risposte riguardo i loro valori nutrizionali.

Gli obiettivi sono due. Il primo è **riprodurre le baseline** riportate in HD-EPIC (Tab. 2, colonna *Nutrition*) per due modelli open da 7B, VideoLLaMA 2 [2] e LLaVA-Video [3], per cui il paper riporta rispettivamente 32.7% e 38.7% contro un 20% casuale. Il secondo è **valutare un metodo di visual prompting**, i Video Panels [4], che a parità di finestra di contesto sostituisce ogni frame con una griglia 2×2 di frame consecutivi: si quadruplica così la copertura temporale al prezzo di un quarto della risoluzione spaziale.

Entrambi gli esperimenti passano da un unico modulo di valutazione, condiviso dai due modelli che fissa il prompt, il parsing delle risposte e le metriche: l'unica parte specifica del modello è la funzione di inferenza. Questo è ciò che rende confrontabili i risultati, perché con parser diversi la differenza di accuracy fra due modelli misurerebbe anche la differenza fra i parser.

I risultati ottenuti sono i seguenti. Le baseline sono riprodotte su tutte le 200 domande: VideoLLaMA 2 ottiene 36.7%, 4.0 punti sopra il valore pubblicato, mentre LLaVA-Video ottiene 38.7%, esattamente il valore pubblicato. I Video Panels, invece, non producono alcun guadagno sulla categoria: 0.0 punti per VideoLLaMA 2 e -1.0 per LLaVA-Video. Il dato più interessante non è però il risultato aggregato, ma il fatto che i due modelli si spostino in direzioni opposte sui due prototipi: VideoLLaMA 2 guadagna con i Video Panels su `nutrition_change` e perde su `video_nutrition_estimation`, mentre LLaVA-Video si comporta in maniera opposta.

2 Dataset e benchmark

HD-EPIC [1] raccoglie 41 ore di video egocentrici registrati in 9 cucine domestiche, per un totale di 156 video di durata media pari a 15.9 minuti. La caratteristica del dataset è il numero delle annotazioni, in media 263 al minuto, che coprono azioni fine-grained, passaggi delle ricette, eventi audio, movimenti degli oggetti, digital twin 3D delle cucine e direzione dello sguardo.

Su queste annotazioni è costruito un benchmark VQA a scelta multipla di circa 26.000 domande, suddivise in sette categorie: *Recipes*, *Ingredients*, *Nutrition*, *Fine-grained Actions*, *3D Perception*, *Object Motion* e *Gaze*.

2.1 La categoria Nutrition

Il lavoro si limita alla categoria *Nutrition*. La categoria comprende 200 domande divise in tre prototipi, riassunti nella Tabella 1. Tutte le domande hanno cinque opzioni, per cui il baseline casuale è del 20%. I video coinvolti sono 50, appartenenti a 8 partecipanti diversi.

Prototipo	N	Input	Domanda
`video_nutrition_estimation`	50	1 video	ingrediente con più carbs/fat/protein/calorie
`nutrition_change`	50	1 video + intervallo	variazione dei 4 valori fra due istanti
`image_nutrition_estimation`	100	5 frame (5 video)	quale dei 5 ingredienti mostrati ha più X

Table 1: I tre prototipi della categoria *Nutrition*. Ogni domanda ha cinque opzioni.

I tre prototipi non richiedono lo stesso tipo di ragionamento. In **video_nutrition_estimation** la domanda riguarda l'intera ricetta e le opzioni sono nomi di ingredienti; in **nutrition_change** la domanda è delimitata da due timestamp espliciti e le opzioni sono quattro valori numerici; in **image_nutrition_estimation** l'input non è un video ma cinque frame isolati, estratti da cinque video diversi a istanti indicati nelle annotazioni. Per questa ultima differenza il prototipo resterà escluso dal secondo esperimento.

Per esempio, una domanda di **video_nutrition_estimation** è *"What is the ingredient with highest carbs in this recipe?"*, con opzioni *butternut squash*, *onions*, *spring greens*, *split red lentils* e una quinta opzione che raggruppa più ingredienti; la risposta corretta è la quarta.

3 Preprocessing dei dati

La preparazione dei dati è stata una parte importante e non trascurabile del lavoro.

3.1 Download

Gli identificativi dei video necessari sono stati estratti dai tre file di annotazione della categoria, ottenendo 50 video distinti appartenenti a 8 partecipanti. Il download è avvenuto in due passaggi: prima tramite il downloader ufficiale del dataset, poi con uno script dedicato che verifica quali file risultino mancanti per ciascun prototipo e li recupera in parallelo dal repository pubblico. Al termine tutti i 50 video sono stati ottenuti in forma utilizzabile: quelli il cui primo download era incompleto sono stati scaricati di nuovo e verificati con il checksum MD5 pubblicato insieme al dataset.

3.2 Sottocampionamento

I video originali durano in media circa 16 minuti, il che li rende non facilmente utilizzabili nell'ambiente di esecuzione. Ogni video è quindi stato ridotto a 128 frame, scelti in modo uniforme su tutta la sua durata e riscritti come video a 1 fps alla risoluzione originale di 1408×1408 pixel. La copertura temporale resta quella dell'intero video, mentre la densità di campionamento scende: si tratta di un'approssimazione rispetto al protocollo originale.

3.3 Estrazione dei frame per `image_nutrition_estimation`

Il prototipo **image_nutrition_estimation** non può usare i video sottocampionati: ogni domanda richiede cinque frame a timestamp esatti, mentre il video a 128 frame contiene un frame ogni 14 secondi circa del video originale, e il frame richiesto in generale non è fra questi. I 132 frame distinti richiesti dalle 100 domande sono quindi stati estratti dai video integrali, all'istante indicato nelle annotazioni. Per non dover scaricare per intero i 47 video coinvolti (circa 58 GB), i frame sono stati letti direttamente dal repository pubblico del dataset, scaricando solo la porzione di file attorno a ciascun timestamp.

3.4 Generazione dei pannelli

Per il secondo esperimento è stata reimplementata la procedura di creazione dei Video Panels a partire dal codice ufficiale del Paper [4]. Dato un video, si estraggono $C \cdot \alpha \cdot \beta$ frame uniformi e li si dispone in C griglie $\alpha \times \beta$ di frame consecutivi fra quelli estratti. Sono stati usati i parametri indicati dagli autori del Paper come configurazione migliore: $C = 32$, $\alpha = \beta = 2$, bordo nullo fra i riquadri e stride temporale $\gamma = 1$. Ogni video produce quindi 32 pannelli che coprono complessivamente 128 frame, gli stessi 128 del video sottocampionato. Viene quindi esteso il contesto temporale mentre diminuisce il contesto spaziale. La Figura 1 ne mostra un esempio.

Il metodo si applica solo quando il video è abbastanza lungo da rendere sensato il processo; in caso contrario si ricade sul campionamento uniforme ordinario.

Prima di ogni esecuzione viene inoltre eseguito un controllo che apre davvero ciascun file richiesto e separa le domande eseguibili da quelle da escludere: una domanda il cui input non è leggibile produrrebbe un'eccezione

che verrebbe contata come risposta sbagliata, abbassando l'accuracy. Con il dataset completo tutte le 200 domande del primo esperimento risultano eseguibili.



Figure 1: Un pannello 2×2: quattro frame consecutivi del video occupano lo spazio di un singolo frame in ingresso al modello.

4 Valutazione e Metriche

Affinché il confronto risulti sensato, tutto tranne il modello è stato gestito in maniera identica. Prompt, interpretazione delle risposte e calcolo delle metriche sono quindi raccolti in un unico modulo condiviso dai due esperimenti sui due modelli: l'unica parte specifica del modello è una funzione di inferenza che riceve l'input visivo e il prompt e restituisce il testo generato. Se ciascun modello avesse il proprio parser, la differenza di accuracy misurata comprenderebbe anche la differenza fra i parser.

4.1 Prompt

Il prompt è deliberatamente minimale e riproduce il formato del paper: la domanda, le cinque opzioni etichettate da A a E, e l'istruzione finale *"Answer with the option's letter from the given choices directly."*.

Non viene usato alcun system prompt, perché il paper di riferimento non ne prevede uno.

Viene impostato in fase di richiesta un limite di 32 token in uscita. La risposta attesa è una singola lettera, quindi il limite non tronca risposte legittime.

4.2 Interpretazione delle risposte

Un modello non sempre risponde nel formato richiesto: può anteporre punteggiatura, premettere una formula come *"the answer is"*, ricopiare il testo dell'opzione invece della lettera, o rispondere con una cifra. Il parsing è quindi organizzato in cinque livelli, applicati in ordine dal più stretto al più permissivo:

1. lettera all'inizio, eventualmente fra parentesi o seguita da punteggiatura;
2. formula esplicita del tipo *answer/option/choice* seguita da una lettera;
3. testo di una delle opzioni ricopiato, purché corrisponda a una sola opzione;

4. una sola lettera valida isolata nel resto del testo;

5. una cifra da 1 a 5, interpretata come indice dell'opzione.

Se nessun livello si applica, la risposta viene marcata come non interpretabile e conteggiata come errata. Il livello che ha prodotto l'esito viene salvato insieme alla risposta grezza del modello, così da poter sempre ispezionare *come* si è arrivati a un certo indice. Il primo livello è costruito in modo da non confondere l'iniziale di una parola con un'etichetta, evitando per esempio di leggere come opzione C la *C* di *"Calories changed by. . . "*.

4.3 Metriche

Il paper di riferimento definisce l'accuracy di una categoria come la **media delle accuracy dei singoli prototipi**, non come l'accuracy aggregata su tutte le domande. Con prototipi di dimensione diversa (50, 50 e 100 domande) i due valori non coincidono, per cui entrambi vengono riportati: il primo è quello confrontabile con i valori pubblicati, il secondo è indicato come accuracy aggregata. Il riferimento casuale è 20%.

Oltre all'accuracy vengono riportate due diagnostiche. La prima è la distribuzione dei metodi di parsing, che dice quanta accuracy si stia eventualmente perdendo per ragioni di formato anziché di contenuto. La seconda è il **bias posizionale**: la distribuzione delle lettere scelte dal modello messa a confronto con quella delle risposte corrette. Se un modello fosse soltanto impreciso, le due distribuzioni si somiglierebbero; se invece sceglie sempre le stesse lettere mentre la risposta corretta è dispersa, non sta rispondendo alla domanda ma seguendo una preferenza a priori sul formato. È la distinzione fra *il modello sbaglia* e *il modello non sta guardando il video*, ed è la spiegazione tipica di un'accuracy inferiore al caso.

4.4 Esecuzione

Ogni risposta viene salvata insieme alla risposta grezza del modello, all'indice predetto, a quello corretto e al metodo di parsing: questo rende ogni esecuzione riprendibile dopo un'interruzione dell'ambiente e, soprattutto, rende i numeri di accuracy verificabili a posteriori riga per riga. Le risposte terminate con un errore di esecuzione (per esempio memoria GPU esaurita) non vengono considerate completate e sono ripetute alla ripresa successiva.

5 Esperimento 1: Valutazione di VideoLLaMA 2 e LLaVA-Video

5.1 Setup

Entrambi i modelli sono stati eseguiti su una singola GPU NVIDIA A100 da 80 GB.

VideoLLaMA 2 7B [2] è stato caricato dal checkpoint ufficiale in precisione `float16`. Il repository forza l'uso di FlashAttention sulla vision tower, che però non lo supporta: è stato necessario sostituirla con l'implementazione *eager* per rendere il modello eseguibile. L'input visivo passa sempre dal preprocessore del repository, che applica ridimensionamento a 336×336, normalizzazione CLIP e padding, sia che riceva il percorso di un video sia che riceva una lista di immagini. Un dettaglio rilevante è che il preprocessore ricampiona l'input a `num_frames`, il cui valore di default è **8**: dei 128 frame preparati a monte, il modello ne vede effettivamente otto.

LLaVA-Video 7B [3] è stato caricato tramite il loader ufficiale in precisione `bfloat16` con attenzione `sdpa`. A differenza del precedente, richiede frame già estratti: il campionamento uniforme viene fatto esplicitamente a **32** frame. La scelta verrà motivata nella sezione riguardante l'esperimento dei Panels.

I due modelli differiscono quindi per quanti frame ricevono. È una differenza che va tenuta presente nel confronto e su cui si torna fra i limiti.

5.2 Risultati

La Tabella 2 confronta i valori ottenuti con quelli pubblicati. Entrambe le baseline sono riprodotte: VideoLLaMA 2 risulta 4.0 punti sopra il valore di riferimento, mentre LLaVA-Video coincide con il valore pubblicato. L'ordinamento fra i due modelli è rispettato, e in entrambi i casi il valore si colloca nettamente sopra il 20% del caso e altrettanto nettamente sotto l'85% degli annotatori umani.

Modello	Paper	Riprodotto	Δ
VideoLLaMA 2 7B	32.7	36.7	+4.0
LLaVA-Video 7B	38.7	38.7	+0.0
Umano	85.0	—	
Casuale	20.0	—	

Table 2: accuracy sulla categoria *Nutrition* (%), come media delle accuracy per prototipo.

Il sottocampionamento dei video rende il nostro protocollo diverso da quello originale, e una differenza di qualche punto è attesa: con 50 domande per prototipo una sola risposta vale 2 punti. Il risultato da trattenere è che i valori sono compatibili con quelli pubblicati, non che siano superiori.

5.3 Dettaglio per prototipo

L'accuracy aggregata nasconde un comportamento molto disomogeneo, riportato nella Tabella 3.

Prototipo (N)	VideoLLaMA 2	LLaVA-Video
`video_nutrition_estimation` (50)	66.0	68.0
`nutrition_change` (50)	16.0	22.0
`image_nutrition_estimation` (100)	28.0	26.0
Media per prototipo	36.7	38.7
Aggregata sulle domande	34.5	35.5

Table 3: accuracy per prototipo (%). I due modelli si comportano in modo molto diverso a seconda del prototipo.

Tre osservazioni:

Il prototipo `nutrition_change` è al livello casuale o sotto. VideoLLaMA 2 ottiene 16.0%, cioè meno del 20% casuale. Il bias posizionale infatti chiarisce: il modello colloca il 58% delle proprie risposte sull'opzione B, mentre le risposte corrette sono distribuite quasi uniformemente sulle cinque lettere. LLaVA-Video mostra lo stesso fenomeno in forma attenuata, con il 42% delle risposte su B e quasi nessuna su E. Su questo prototipo i modelli non stanno rispondendo alla domanda: stanno seguendo una preferenza a priori sul formato. È coerente con la natura del compito, che richiede di leggere valori numerici su una bilancia digitale in un intervallo di pochi secondi e di sceglierne la variazione fra cinque quaterne di numeri simili. A questo si aggiunge che il modello riceve frame campionati uniformemente su tutto il video senza l'indicazione dell'istante a cui ciascuno corrisponde: i timestamp citati nella domanda non sono quindi collegabili ai frame, e un intervallo di pochi secondi in un video di un quarto d'ora quasi sempre non cade su nessuno dei frame ricevuti.

Il prototipo `video_nutrition_estimation` è molto sopra la media di categoria, con il 66% per VideoLLaMA 2 e il 68% per LLaVA-Video. Una spiegazione plausibile è che molte di queste domande siano risolvibili con la sola conoscenza linguistica, senza guardare il video: sapere che le lenticchie contengono più carboidrati della cipolla non richiede evidenza visiva.

Il prototipo `image_nutrition_estimation` resta vicino al caso, con il 28% e il 26%. Ogni domanda chiede quale dei cinque ingredienti inquadrati abbia più calorie, grassi, carboidrati o proteine, e anche qui le opzioni sono nomi di ingredienti. Il divario con il prototipo precedente suggerisce che la sola conoscenza

linguistica non basti: un'ipotesi plausibile, non verificata in questo lavoro, è che i valori nutrizionali delle annotazioni si riferiscano alla quantità effettivamente usata nella ricetta, visibile solo nelle immagini, e non all'ingrediente in astratto.

6 Esperimento 2: Valutazione dei VLM con la tecnica dei Video Panels

6.1 Il metodo e la condizione del confronto

I Video Panels [4] affrontano un vincolo strutturale dei VLM: la finestra di contesto limita quanti frame possono essere dati in pasto al modello, e su un video lungo questo significa un campionamento molto rado. Si può quindi ridurre risoluzione spaziale dove non serve: ogni elemento della sequenza in ingresso, invece di contenere un frame, contiene una griglia $\alpha \times \beta$ di frame consecutivi. A parità di elementi in ingresso la copertura temporale si moltiplica per $\alpha\beta$, riducendo di altrettanto il contesto spaziale di ciascun frame.

Il confronto è quindi sensato solo *a parità di finestra di contesto*, ed è in questa condizione che è stato condotto. Per VideoLLaMA 2, che ricampiona internamente a 8 elementi, si confrontano 8 frame contro 8 pannelli, cioè 8 contro 32 frame di copertura. Per LLaVA-Video, che lavora con 32 frame, si confrontano 32 frame contro 32 pannelli, cioè 32 contro 128. In entrambi i casi il modello riceve lo stesso numero di elementi visivi nelle due condizioni e quadruplica la copertura temporale passando ai pannelli; cambia il regime assoluto in cui la cosa avviene.

L'esperimento è limitato ai due prototipi basati su video, per un totale di 99 domande valutate. **image_nutrition_estimation** è escluso in quanto il suo input è costituito da cinque frame isolati provenienti da cinque video diversi, quindi non esiste alcuna sequenza temporale da impacchettare e il metodo non è applicabile.

6.2 Risultati

	VideoLLaMA 2		LLaVA-Video	
Prototipo	base	panels	base	panels
`video_nutrition_estimation`	66.0	62.0	68.0	72.0
`nutrition_change`	16.3	20.4	20.4	14.3
Media per prototipo	41.2	41.2	44.2	43.2
Δ	0.0		-1.0	

Table 4: Video liscio contro pannelli 2×2, a parità di finestra di contesto e sulle stesse 99 domande. I valori del baseline differiscono da quelli della Tabella 3 perché calcolati sul sottoinsieme ristretto ai due prototipi video.

Il risultato aggregato, riportato nella Tabella 4, è che **i Video Panels non producono alcun guadagno** sulla categoria *Nutrition*: 0.0 punti per VideoLLaMA 2 e -1.0 per LLaVA-Video. Entrambe le variazioni sono troppo piccole per essere distinte dal rumore di campionamento e vanno lette come assenza di effetto, non come peggioramento.

È interessante notare che i due modelli si spostano in **direzioni opposte sugli stessi prototipi**, con variazioni di ampiezza simile e segno contrario: VideoLLaMA 2 guadagna 4.1 punti su `nutrition_change` e ne perde 4.0 su `video_nutrition_estimation`, mentre LLaVA-Video fa il contrario, guadagnando 4.0 punti su `video_nutrition_estimation` e perdendone 6.1 su `nutrition_change`.

Va detto con chiarezza che su prototipi da circa 50 domande una variazione di 4 punti corrisponde a due domande: nessuno di questi scarti è statisticamente significativo preso singolarmente.

6.3 Osservazioni sul Visual Prompting

Applicare la tecnica dei Video Panels (**Visual Prompting**) non ha portato i vantaggi desiderati. I Video Panels scambiano risoluzione spaziale per risoluzione temporale, e questo è vantaggioso quando l'informazione rilevante è *dove e quando* accade qualcosa di visivamente evidente. Il prototipo `nutrition_change` richiede però di leggere *cifre* sul display di una bilancia digitale: dividendo per quattro l'area di ciascun frame si degrada esattamente il tipo di dettaglio da cui dipende la risposta. Questo è coerente con il calo di LLaVA-Video su questo prototipo; VideoLLaMA 2, che nel baseline vede solo 8 frame, mostra invece un lieve miglioramento, compatibile con un maggior beneficio della copertura temporale quando i frame sono molto pochi. In entrambi i casi, però, le variazioni restano entro il rumore di campionamento e i due modelli rimangono vicini al livello casuale.

7 Discussione e conclusioni

7.1 Limiti

I risultati vanno letti tenendo presenti alcuni limiti, che riguardano sia i dati sia il disegno sperimentale.

Dati. I video sono stati sottocampionati a 128 fotogrammi anziché usati per intero, per i due prototipi basati su video; solo `image_nutrition_estimation` usa i frame originali agli istanti indicati dalle annotazioni. L'insieme di valutazione coincide invece con quello originale: tutte le 200 domande sono state valutate.

Frame ricevuti. I due modelli vedono un numero diverso di frame (8 per VideoLLaMA 2, 32 per LLaVA-Video), per cui il confronto diretto fra i due modelli mescola l'effetto dell'architettura con quello della quantità di input.

Riferimento temporale. Le domande di `nutrition_change` citano due istanti precisi del video, ma i modelli ricevono frame campionati uniformemente senza l'indicazione del tempo corrispondente; in questo protocollo il prototipo misura quindi anche la capacità di collegare i timestamp della domanda a frame che quasi sempre non li contengono.

Ambito. Il lavoro copre una sola delle sette categorie del benchmark. Le conclusioni valgono per *Nutrition* e non sono estendibili alle altre senza ulteriori esperimenti.

7.2 Sviluppi possibili

Si individuano tre direzioni. La prima è eseguire un **baseline testuale**, cioè sottoporre le stesse domande a un modello senza accesso al video: è la misura che manca per stabilire quanta parte dell'accuracy su `video_nutrition_estimation` dipenda da conoscenza linguistica anziché da comprensione visiva, ipotesi che qui resta formulata ma non verificata. La seconda è variare la geometria dei pannelli, in particolare verso griglie più grandi su un modello con finestra di contesto ampia, per capire se il compromesso fra risoluzione spaziale e temporale abbia un punto ottimale diverso su questo dominio. La terza è applicare i panels non all'intero video ma solo alle parti del video più rilevanti per rispondere alla domanda, per esempio l'intervallo indicato nelle domande di `nutrition_change`.

7.3 Conclusioni

Il lavoro ha riprodotto le baseline della categoria *Nutrition* del benchmark VQA di HD-EPIC [1] per due VLM open da 7 miliardi di parametri, ottenendo 36.7% per VideoLLaMA 2 [2] e 38.7% per LLaVA-Video [3], contro i 32.7% e 38.7% riportati dagli autori. Su questa base ha poi valutato i Video Panels [4] come metodo di visual prompting, trovando che a parità di finestra di contesto non producono alcun guadagno sulla categoria, e che il loro effetto si distribuisce in modo opposto sui due prototipi a seconda del modello.

References

[1] T. Perrett et al. *HD-EPIC: A Highly-Detailed Egocentric Video Dataset*. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.

[2] Z. Cheng et al. *VideoLLaMA 2: Advancing Spatial-Temporal Modeling and Audio Understanding in Video-LLMs*. arXiv:2406.07476, 2024.

[3] Y. Zhang et al. *Video Instruction Tuning with Synthetic Data*. arXiv:2410.02713, 2024.

[4] L. Doorenbos, F. Spurio, J. Gall. *Video Panels for Long Video Understanding*. arXiv:2509.23724, 2025.